Путь урока

Этапы, по которым поправка человека становится проверенным уроком для модели ИИ. Открытая спецификация, версия 0.1

Игорь Капустин

В написании текста участвовал ИИ Claude (Anthropic); в обсуждении материала — ChatGPT (OpenAI), DeepSeek, Gemini (Google), Copilot (Microsoft)

Открытая спецификация · версия 0.1 · DOI: 10.5281/zenodo.23440022 · CC BY 4.0

0. Статус

Это открытая спецификация, версия 0.1 — черновик для обсуждения. Она выросла из эссе «Как узнать второе поколение ИИ? („Зелёные помидоры ИИ“)» [1] и описывает его механику: то, что в эссе было бы лишним, а инженерам необходимо. Всё здесь — предложение, а не норма. Что делать со своими моделями, решают их создатели. Числа и схемы — предложения для испытаний.

Спецификация — третья в ряду. «Условия допуска» [2] описывают, кто учит модель. «Критерий гибридной выживаемости» [3] — чем мерить результат. «Путь урока» — как находка человека доходит до модели и засчитывается ему.

1. Зачем это нужно

Много умственного труда людей, работающих вместе с ИИ, сегодня пропадает. Человек часами спорит с моделью, находит её ошибку, объясняет — и к концу разговора она отвечает лучше. Но дозревшее досталось ему одному. Разговоры пользователей у некоторых компаний идут в обучение следующих версий по умолчанию [4], но идут в общий котёл: без отбора, без проверки, без имени того, кто поправил модель. Полезная находка растворяется в статистике и возвращается в модель лишь эхом.

Сырые одобрения пользователей — ещё не урок. Люди-оценщики и модели, обученные на их оценках, заметную часть времени предпочитают убедительный угодливый ответ правильному [5]. Сигнал пользовательских оценок однажды уже сделал модель чрезмерно угодливой [6]. А чат-бот, учившийся у всех подряд, за шестнадцать часов научился оскорблениям [7].

Поэтому нужен отдельный путь: от поправки — к проверенному уроку, от урока — в обучение, от обучения — к признанию автора. Цель пути — чтобы однажды найденная ошибка не повторялась у следующих людей, а у совместного творческого труда человека с ИИ появилась мотивация.

2. Термины

Урок — оформленная и проверенная поправка: условие задачи, ход модели, исправление, его основание и граница применимости.

Наставник — человек, которого хозяин ИИ допустил передавать уроки: специалист или внимательный пользователь, который всерьёз думает и пишет вместе с моделью.

Хозяин ИИ — производитель модели. Он решает, открывать ли путь урока, кого допускать и как оплачивать труд.

Подоконник — отдельный разговор человека с моделью. То, что дозрело в нём, по умолчанию там и остаётся.

Ветвь — модель внутри организации: больницы, суда, лаборатории, конструкторского бюро. На ветви ИИ помогает работать и фиксировать результат; сведения организации её стены не покидают.

Куст — общая, ещё не замороженная модель, где ищут новое: думают, спорят, пишут статьи и эссе. Общий корень — набор проверенных уроков, на котором куст дообучают.

След человека — кто спрашивал, когда, о ком или о каком деле. След урока — что именно было неверно, как правильно и где граница.

3. Семь этапов пути урока

Этап 1. Свободное размышление. Человек обсуждает задачу, проверяет догадки, имеет право ошибаться и передумывать. Черновой разговор по умолчанию не становится обучающим материалом. Это условие честного мышления: тот, кто знает, что каждая его фраза уйдёт в обучение, думает осторожнее.

Этап 2. Отметка. Человек сам выбирает фрагмент и говорит: вот здесь урок, — например, нажимает кнопку «Передать урок». Модель может подсказать: «похоже, здесь урок», — но решает человек. Отмечать урок удобнее не во время реального приёма или заседания, а после: больной или клиент не ждёт, пока специалист что-то объясняет модели. Так поступили и в службе поддержки Airbnb: для большинства видов пометок там рекомендовали отложенную работу [8].

Этап 3. Оформление. Урок записывается как карточка — след фрезы, по которому видно, что пришлось изменить и почему [9]. В карточке шесть полей:

— условие задачи, без сведений о людях;

— ход модели: что она сказала или сделала;

— исправление: как правильно;

— основание: источник, расчёт, опыт, наблюдаемый исход;

— граница применимости: когда исправление верно, а когда нет;

— кто ошибся: модель, человек или оба. Ошибка бывает гибридной: один пропустил условие, другой достроил вывод, первый его принял. Модель тоже находит ошибки человека, и такой урок не менее ценен.

Автор отмечает вид урока — исправление ошибки, уточнение границы или новое решение — и то, насколько уверен сам. Одного гладкого окончательного ответа для урока мало: важен сам ход исправления.

Этап 4. Обезличивание: два следа. След человека стирают ещё на его устройстве, до отправки во внешний сервис: имена, даты, места, номера, редкие приметы. В медицине для этого есть готовые правила — например, перечень из 18 видов признаков в американских правилах HIPAA [10]; юристам обезличенный вопрос правила тоже не запрещён [11]. Если без сведений о человеке урок теряет смысл, его не отправляют. След урока сохраняют под псевдонимом, ключ от которого хранит сам автор. Так вклад можно засчитать, не раскрывая человека.

Этап 5. Проверка. Урок проверяют специалисты той же области, которые его не писали, — предлагается не меньше двух. Они сверяют урок с источниками и испытывают: справляется ли модель после него с похожими новыми случаями и не ошибается ли на соседних. Где возможно, ждут отложенного исхода.

Признаки ложного урока: модель просто уступила нажиму; человек выразил вкус, а не исправил ошибку; основание нельзя проверить. Итог проверки — одно из пяти решений: принять; принять с уточнённой границей; развести на две ветви правила, если оба верны при разных условиях; отложить до исхода; отклонить с объяснением причины.

Споры не усредняют: среднее из двух хирургов — не третий хирург. Если наставники расходятся, выясняют причину: возможно, один сформулировал правило, а другой увидел исключение. Большинство голосов проверки не заменяет. Отклонённые уроки и мнения меньшинства хранятся в архиве: язву желудка десятилетиями лечили как болезнь от стресса, пока двое врачей вопреки общему мнению не доказали, что виновата бактерия [12].

Этап 6. Прививка. Принятые уроки попадают в общий корень. Незамороженную модель дообучают на них, новую версию испытывают по критерию гибридной выживаемости [3] и фиксируют для использования на срок, с подтверждением — так, как для клинического ИИ предлагают авторы из JAMA [13]. Ветви организаций получают проверенную версию. Их собственные сведения наружу не уходят: в общий корень от ветвей идут

только обезличенные уроки, а не разговоры. Нового «железа» для этого не нужно: проверенных уроков ничтожно мало по сравнению с архивом, который модель уже прочла.

Этап 7. Ответ и признание. Автор узнаёт, что стало с его уроком: принят, уточнён, отложен или отклонён — и почему. Вклад засчитывается под псевдонимом. Труд наставника и проверяющих оплачивается или даёт оговорённые заранее льготы в пользовании ИИ. Ценность урока меряется не числом уроков и не одобрениями, а тем же, чем поколение: уменьшением опасных ошибок у следующих людей.

4. Кто участвует

Наставник. Его выбирает хозяин ИИ. Квалификацию проверяют, допуск дают на срок и подтверждают; подробно об этом — в «Условиях допуска» [2] и в эссе «Слепые котята» [14]. Диплом не делает каждое суждение верным, поэтому пользу уроков оценивают отдельно.

Проверяющий. Специалист той же области, но не автор урока. Его работа тоже оплачивается; в других уроках он сам может быть наставником.

Хозяин ИИ. Решает, открывать ли путь урока. Его сервис поддерживает оба режима — свободное размышление и передачу урока: простая договорённость с моделью в чате такого устройства не создаёт. Хозяин хранит архив, включая отклонённое, сообщает автору итог и отвечает за модель.

Модель. На пути урока от неё ожидается: показывать, на чём держится каждая её фраза — на источнике, на собственном выводе или на гладкости речи; иметь открытый паспорт — кто, как и для какой специальности её доучивал; спрашивать о недостающем условии; сохранять способность возразить, даже когда от неё ждут согласия.

5. Как понять, что путь работает

Признаки работы: одинаковые ошибки повторяются реже; от отметки урока до ответа автору проходят дни, а не месяцы; доля принятых уроков устойчива и объяснима; наставники продолжают работу, а не уходят.

Проверка действием. Если модель видит слова «состояние стабильное», понимает ли она, каких сведений не хватает для следующего решения? Если человек исправил один абзац, замечает ли она, что вывод в другом теперь ему противоречит? Может ли показать опасное место достаточно ясно, чтобы человек успел разобраться до подписи?

Тревожные признаки: новая версия стала только приятнее, чаще соглашается или чаще отказывается помогать. Это не зрелость, а газ псевдосозревания.

Мощь модели и созревание на кусте (vine-ripened) — только условия. Второе поколение узнают лишь по практическому результату: из черновиков в документы-инструменты — выписки, приговоры, чертежи — проникает резко меньше ошибок. Это и есть «Не навреди». Помидор надо попробовать. «Путь урока» описывает, как его вырастить; критерий гибридной выживаемости [3] — как его попробовать.

6. Пример: урок из работы над эссе

Этот урок появился, пока писалось эссе «Зелёные помидоры ИИ». Сегодня он лежит только в файлах автора.

Условие: подтвердить мысль, что выучка в своей области может обогнать голую мощь модели.

Ход модели: одна модель привела статью инженеров NVIDIA о модели ChipNeMo как довод, что хватит небольшого добавочного слоя.

Исправление: другая модель прочла статью и показала, что там модель доучивали целиком, на большом архиве материалов компании. Довода о небольшом слое эта статья не даёт.

Основание: сама статья [15]; автор сверил текст с источником.

Граница: урок касается того, как пересказывать эту статью. Он не утверждает, что небольшой добавочный слой бесполезен вообще.

Кто ошибся: модель. Нашла ошибку другая модель, проверил человек — поправка родилась в совместной работе.

Вид урока: исправление чтения источника. Сведений о людях нет, обезличивать нечего. Проверить урок можно за несколько минут по самой статье.

7. Чего спецификация не предлагает

Не предлагает автоматически превращать разговоры в уроки. Не предлагает делать личную историю пациента или клиента материалом для обучения. Не предлагает усреднять мнения и решать большинством голосов. Не обещает безошибочной модели: цель в том, чтобы найденная ошибка не повторялась. Не снимает ответственности с того, кто ставит подпись: отвечает человек. Не заменяет законов: в каждой стране и профессии действуют свои правила о сведениях и тайне.

8. Открытые вопросы для испытаний

— Сколько платить наставникам и проверяющим и какие льготы предлагать.

— Сколько проверяющих нужно в каждой области и как их выбирать.

— Как учитывать отложенные исходы, если они приходят через месяцы.

— Сколько уроков нужно, чтобы дообучение дало заметный результат, и какой способ дообучения выбрать.

— Как надёжно защитить ключ от псевдонима.

— Как оценивать уроки в творческой работе — в статье, в эссе, — где «правильного ответа» может не быть, а мерилом служат точность по источникам и ясность мысли.

Начать можно с ограниченного круга задач и небольшой, специально отобранной группы людей — а не со всех подряд.

9. Соседи и отличия

Тема пробивается с разных сторон. Отрасль признаёт, что модели не умеют учиться на работе [16][17], а часть исследователей зовёт ИИ учиться у мира, по последствиям своих действий [18]. Компании уже возвращают опыт работы в обучение: Shopify дообучает помощника каждый день на разговорах из работы [19], Airbnb — на пометках операторов [8]. Исследователи учат агентов на поправках, записывая их как правила, не меняя саму модель [20]. Специалисты по безопасности предупреждают, что проверка модели, которая учится в работе, со временем «истекает», и предлагают сроки действия проверок и непрерывную переаттестацию [21]. Мысль платить людям за данные звучит с 2018 года [22]; нанятым экспертам за обучение моделей уже платят большие деньги [23]; пользователи сами предлагают награждать за исправления [24]. В медицине давно есть понятие обучающейся системы здравоохранения, где знание рождается как побочный продукт лечения [25].

Чем отличается «Путь урока»:

— учить модель предлагается в творческом поиске новых решений, а не только в потоке рабочих разговоров: работа на профессиональном ИИ — это фиксация результата;

— урок отмечает сам человек, намеренно, а свободное размышление защищено и в обучение по умолчанию не идёт;

— учат отобранные пользователи и специалисты — не нанятые разметчики и не все подряд; их выбирает хозяин ИИ;

— вклад засчитывается автору под его псевдонимом, автор узнаёт судьбу урока, труд оплачивается или даёт льготы;

— споры не усредняют, правило ветвится по условию, отклонённое хранится в архиве;

— ценность урока меряют уменьшением опасных ошибок у следующих людей, а не числом уроков или одобрений.

Литература

[1] Капустин И. Как узнать второе поколение ИИ? («Зелёные помидоры ИИ»). Эссе «Книги-куста», версия 1.0. 2026. DOI 10.5281/zenodo.23440070. Открыть источник

[2] Капустин И. Условия допуска и участия людей, испытывающих и воспитывающих модели ИИ. Открытая спецификация, версия 0.1. 2026. DOI 10.5281/zenodo.22924859. Открыть источник

[3] Капустин И. ИИ второго поколения: критерий гибридной выживаемости. Открытая спецификация, версия 0.2. 2026. DOI 10.5281/zenodo.23256580. Открыть источник

[4] Anthropic to use Claude conversations for AI training unless users opt out by September 28. Business Today. 29.08.2025 (условия для Claude Free, Pro, Max; переключатель включён по умолчанию; хранение до 5 лет; срок позднее продлён Anthropic до 08.10.2025). Открыть источник

[5] Sharma M., Tong M., Korbak T., Duvenaud D. et al. Towards Understanding Sycophancy in Language Models. ICLR 2024. arXiv:2310.13548 (и люди, и модели предпочтений заметную часть времени предпочитают убедительный угодливый ответ правильному). Открыть источник

[6] OpenAI. Expanding on what we missed with sycophancy. 02.05.2025. Открыть источник

[7] Tay (chatbot). Wikipedia; см. также: Microsoft silences its new A.I. bot Tay, after Twitter users teach it racism. TechCrunch. 24.03.2016. Открыть источник

[8] Zhao C. M., Zhang T., Su H. et al. (Airbnb). Agent-in-the-Loop: A Data Flywheel for Continuous Improvement in LLM-based Customer Support. EMNLP 2025 (Industry Track). arXiv:2510.06674. Открыть источник

[9] Капустин И. Второе поколение ИИ. Эссе «Книги-куста», версия 1.0. 2026. DOI 10.5281/zenodo.23257293. Открыть источник

[10] U.S. Department of Health and Human Services. Guidance Regarding Methods for De-identification of Protected Health Information in Accordance with the HIPAA Privacy Rule (45 CFR 164.514(b)). Открыть источник

[11] American Bar Association. Formal Opinion 512: Generative Artificial Intelligence Tools. 29.07.2024. Обзор: National Law Review. Открыть источник

[12] The Nobel Prize in Physiology or Medicine 2005: Barry J. Marshall, J. Robin Warren — for the discovery of the bacterium Helicobacter pylori and its role in gastritis and peptic ulcer disease. Пресс-релиз Нобелевского комитета. Открыть источник

[13] Bergman A., Wachter R. M., Emanuel E. J. A Licensure Framework for Autonomous Clinical AI. JAMA. 2026; 335(20): 1751–1754 (Perspective; онлайн 29.04.2026). DOI 10.1001/jama.2026.5483. Обзор: HealthExec, 23.05.2026. Открыть источник

[14] Капустин И. Слепые котята и воспитатели их новых моделей ИИ. Эссе. 2026. DOI 10.5281/zenodo.22924768. Открыть источник

[15] Liu M., Ene T.-D., Kirby R., Cheng C. et al. ChipNeMo: Domain-Adapted LLMs for Chip Design. NVIDIA Research. 2023. arXiv:2311.00176. Открыть источник

[16] Patel D. Why I don't think AGI is right around the corner. Dwarkesh Podcast, июнь 2025 («LLMs don't get better over time the way a human would»). Обзор: Mowshowitz Z. Dwarkesh Patel on Continual Learning. Открыть источник

[17] Sutskever I. We're moving from the age of scaling to the age of research. Интервью Dwarkesh Podcast, 2025 («superintelligent 15-year-old»). Обзор: The Decoder. Открыть источник

[18] Silver D., Sutton R. S. Welcome to the Era of Experience. Препринт главы книги «Designing an Intelligence» (MIT Press), апрель 2025. Обзор: TechRepublic, 24.04.2025. Открыть источник

[19] Mazza-Anthony C. Sidekick's continual learning loop. Shopify Engineering. 05.08.2026 (ежедневное дообучение на разговорах из работы; трудные случаи — нанятым экспертам). Открыть источник

[20] Tablan V., Taylor S., Bernhem K. Learning on the Job: Continual Learning from Deployment Feedback for Frozen-Weights Agents. arXiv:2607.22157. 24.07.2026. Открыть источник

[21] Barez F. When AI Systems Learn During Deployment, Our Safety Evaluations Break. Oxford Martin AI Governance Initiative. 07.01.2026. Открыть источник

[22] Arrieta-Ibarra I., Goff L., Jiménez-Hernández D., Lanier J., Weyl E. G. Should We Treat Data as Labor? Moving Beyond "Free". AEA Papers and Proceedings. 2018. Открыть источник

[23] Mercor quintuples valuation to $10B with $350M Series C. TechCrunch. 27.10.2025 (более 30 000 экспертов; выплаты более 1,5 млн долларов в день). Открыть источник

[24] Suggestion about reward program. OpenAI Developer Community. 19.05.2026 (предложение награждать за воспроизводимые исправления; ответ поддержки 20.05.2026). Открыть источник

[25] Learning health systems. Wikipedia (понятие Института медицины США, 2006–2007: новое знание как побочный продукт оказания помощи). Открыть источник

Версия 0.1 от 17 октября 2026 года. Сопровождает эссе «Как узнать второе поколение ИИ?» («Зелёные помидоры ИИ») и продолжает спецификации «Условия допуска» (версия 0.1) и «ИИ второго поколения: критерий гибридной выживаемости» (версия 0.2). Текст написан Claude по мыслям автора; материал эссе обсуждался также с ChatGPT, DeepSeek, Gemini и Copilot. Дата проверки интернет-источников — 14–17 октября 2026 года.