ИИ второго поколения

Критерий гибридной выживаемости. Открытая спецификация, версия 0.2

Игорь Капустин

В написании текста участвовали ИИ: Claude (Anthropic), ChatGPT (OpenAI)

Открытая спецификация · версия 0.2 · DOI: 10.5281/zenodo.23256580 · CC BY 4.0

0. Статус

Это открытая спецификация, версия 0.2. Она выросла из эссе «Второе поколение ИИ» [1] и излагает его мысли в проверяемой форме. Всё здесь — предложение для обсуждения, а не установленная норма; следующие версии будут учитывать критику. Числа и схемы испытаний — предложения, а не готовый стандарт. Критика приветствуется.

1. Назначение и границы

Спецификация предлагает определять поколение ИИ не по мощности, скорости или широте способностей модели, а по тому, насколько безопаснее становится гибридная система «человек + ИИ» — для самого человека, для людей вокруг и для тех, кого затронет результат совместной работы.

Первая область применения — гибридные тексты, которые подписывает человек: заключения, решения, приказы, отчёты, публикации. Определение задумано шире текстов и годится для ИИ, который действует в мире сам; для этого нужен отдельный профиль испытаний (раздел 9).

Соответствие второму поколению подтверждается не «вообще», а для определённого применения: задачи, типа документов, группы операторов, версии модели, инструментов и условий работы. Например: «критерий П2 подтверждён для подготовки выписных эпикризов врачами-терапевтами». Положительный результат у опытных специалистов не переносится автоматически на других пользователей. Полезно различать три состояния: «подтверждено», «не проверено», «проверено и не соответствует».

2. Термины и природа гибридного текста

Гибридная система — человек-оператор и ИИ, работающие над одним результатом. Оценивается связка, а не каждая сторона отдельно.

Оператор (автор) — человек, который управляет работой и подписывает результат.

Гибридный черновик, «болванка» — заготовка, в которой смешаны машинное начало, человеческие дополнения и совместные переделки.

Инструментальный текст — текст, по которому другие люди принимают решения или действуют: заключение врача, приговор, приказ, государственное решение, новость.

Подпись — любой акт, после которого текст получает право действовать: подпись, публикация, отправка, утверждение, действие по тексту.

Ошибка — неверность, существенное упущение или иной дефект результата.

Опасность — возможность причинить вред в определённых условиях. Опасным может быть и верный текст: например, если он раскрывает чужие конфиденциальные сведения.

Вред — фактически наступившее последствие. Не всякая ошибка приводит к вреду; на испытательном стенде измеряется прежде всего опасность, а не наступивший вред.

Выявленный риск — фрагмент гибридного черновика или пропуск в нём, отмеченный системой или человеком как потенциально опасный.

Гибридный текст — новый вид текста, которого прежде не было на планете в таком количестве. Его свойства и делают нужной эту спецификацию:

Разноприродность создателей. Его пишут человек и машина — создатели разной сущности. Они говорят будто бы на одном человеческом языке, но вкладывают в одни слова разное [2]. Единство языка иллюзорно; ошибки прячутся в его щелях.

Инструментальность. По нему действуют: лечат, судят, учат, приказывают, принимают государственные решения.

Скорость синтеза, оборачиваемость и масштабируемость. Он появляется за секунды, быстро расходится и тиражируется.

Заразность. Его цитируют и пересказывают люди, на нём учатся следующие модели ИИ [3]. Ошибка в нём склонна размножаться — и среди людей, и среди машин.

Вместе эти свойства делают незаметную ошибку гибридного текста опаснее ошибки обычного текста.

3. Определение: гибридная выживаемость

Поколение ИИ определяется гибридной выживаемостью человека-оператора и машины — их единой системы. Под гибридной выживаемостью понимается безопасность этой системы и людей, которых она затрагивает. Система тем совершеннее, чем ниже риск вреда в трёх кругах:

К1 — для самого оператора. Пилот возвращается на аэродром; автор не остаётся один на один с тем, чего не может проверить.

К2 — для людей вокруг во время работы системы. Вред возможен и до выпуска текста: раскрытие сведений о других людях, передача материала неподходящему получателю, небезопасное использование внешнего инструмента. Когда ИИ действует сам, этот круг становится главным.

К3 — для людей, которых затронет результат работы. Это главный круг для инструментальных текстов.

Круги — способы рассмотреть вред, а не непересекающиеся группы: один и тот же человек может оказаться в нескольких кругах.

Мощность, скорость и красноречие модели в определение не входят. Модель может быть сильной во всём этом и оставаться первым поколением.

Версия 0.2 предлагает прежде всего испытание предотвращения потенциально вредных ошибок в текстах (К3, частично К1). Полная проверка всех трёх кругов требует дополнительных показателей.

4. Поколения

Первое поколение (П1) расширяет возможности человека: помогает быстрее и больше писать, искать, рассуждать. Отдельные средства защиты у него могут быть, но подтверждённое снижение вредных ошибок в совместной работе не служит основанием его классификации.

Второе поколение (П2) расширяет и защищает. Критерий: при работе с ним до людей доходит заметно меньше опасных ошибок, чем при сравнении (раздел 7), на сопоставимых задачах и в сопоставимых условиях — при сохранении полезности и своевременности работы и в пределах допустимого остаточного риска. Система, которая просто ничего не выпускает, преимущества не получает. Защита достигается профилактикой, а не юридической оговоркой и не смягчением ответственности.

Третье поколение (П3), гипотеза: практически полное предотвращение опасных ошибок. Это область предположений; критериев для неё спецификация не задаёт.

5. Два утверждения: результат системы и вклад модели

Спецификация различает два утверждения, которые проверяются по-разному.

Утверждение А — результат системы: совместная работа даёт меньше опасных ошибок. Проверяется сравнением рабочих процессов.

Утверждение Б — вклад обучения: специальное обучение модели внесло измеримый вклад в это снижение. Проверяется, по возможности, сравнением

одной базовой модели до и после обучения при одинаковых инструментах и интерфейсе.

Результат А не доказывает Б: безопасность может достигаться поиском, интерфейсом, организацией проверки или их сочетанием. Автор считает специальное обучение модели сутью второго поколения, поэтому полное соответствие П2 предполагает подтверждение обоих утверждений.

6. Функции модели второго поколения

Ниже — способности, которые, вероятно, нужны модели П2. Основной результат модели — структурированное замечание: фрагмент или пропуск; причина сомнения; подтверждающий материал (конкретный фрагмент источника, дата или версия, а если источника нет — явная отметка об этом); возможное последствие; следующий шаг проверки. Способ отображения — шрифт, цвет, в будущем, возможно, осязаемые подсказки — относится к интерфейсу.

Ф1. Использует доступную историю создания и редактирования, чтобы показать, что написала машина, что добавил человек и что переделано вместе. Отмечает неизвестное происхождение и недоступные части контекста. Происхождение не угадывается по стилю и не служит мерой достоверности: человеческий текст не получает презумпции правильности, машинный — неправильности.

Ф2. Ищет ошибки обеих сторон — свои и человека, а также ошибки взаимодействия: дефекты, возникшие при соединении по отдельности приемлемых фрагментов, и пропуски — исчезнувшие условия, исключения, необходимые сведения.

Ф3. Замечает смысловые сдвиги при правках («след фрезы»): где исчезло условие, где предположение стало утверждением, где вывод вышел за пределы основания. Существенная правка отмечает связанные выводы и ранее проверенные места, которые теперь стоит проверить заново: отметка «проверено» относится к определённой версии текста.

Ф4. Выдаёт замечания в структурированном виде (см. выше), привязанные к месту в тексте.

Ф5. Помогает расставить приоритеты и не отмечает всё подряд. Показывает отдельно предполагаемую тяжесть последствия, основания подозревать ошибку и неопределённость своей оценки, не сводя их в непрозрачный балл. Редкая тяжёлая ошибка может заслуживать внимания раньше частой мелкой.

Ф6. Показывает, какой вывод не следует из приведённых данных и каких сведений не хватает для проверки, и предлагает безопасный выход:

запросить сведения, ограничить утверждение, убрать фрагмент, отложить выпуск или привлечь специалиста.

Ф7. Помогает искать опровергающие данные и альтернативные объяснения, а не только подтверждения уже принятого вывода [4]. Эффективность этой помощи проверяется по решениям человека. Расхождение нескольких моделей может служить сигналом для проверки; их согласие само по себе истинности не подтверждает.

Ф8. Делает основания и ограничения материала за гранью компетенции оператора доступнее для проверки — как слияние данных в кабине истребителя сводит показания датчиков в одну картину [5]. И показывает, какие вопросы остаются за пределами компетенции оператора: иногда лучшая помощь — увидеть, что нужен специалист.

7. Порог подписи

Подписывать разумно тогда, когда все выявленные существенные риски — отмеченные системой или человеком — рассмотрены применительно к текущей версии текста. Человек не может подтвердить разбор неизвестных опасностей; он может подтвердить разбор выявленных.

Исходы разбора: исправлено; основание проверено; сведения уточнены; фрагмент удалён; предупреждение обоснованно отклонено; выпуск отложен; вопрос передан специалисту.

Одного нажатия «ознакомлен» недостаточно. Отсутствие отметок не означает отсутствия ошибок: проверяющая модель тоже ограничена. Это необходимый этап, а не доказательство безошибочности.

Если используется замок на выпуск, описывается его поведение при исправлении текста, при ошибке самого предупреждения и при техническом сбое.

Запись разбора фиксирует решение по каждому вопросу и служит профилактике и защите людей, а не назначению виноватого. Она хранит и то, что система показала, и сколько времени было у человека. Доказать одним щелчком действительное понимание человека запись не способна.

8. Испытание

Принадлежность к П2 подтверждается не заявлением разработчика, а испытанием гибридной системы. Предлагаются два последовательных испытания.

Испытание 1 — проверка готового черновика. Разные участники получают сопоставимые исходные черновики. Сравнивается, какие опасные ошибки

они пропускают и какие вносят при исправлении. Так проверяется работа функции проверки.

Испытание 2 — полный цикл: подготовка, совместное редактирование, проверка и решение о выпуске. Так проверяется итоговый результат совместной системы. Успех в испытании 1 ещё не подтверждает успех в испытании 2.

Сравнение задаётся заранее. Для проверки специальной функции наиболее содержательно сравнить модель-кандидат с обычной моделью, получившей хорошую инструкцию на проверку. Сравнение с работой без ИИ отвечает на другой вопрос.

Набор документов включает естественные ошибки, специально внесённые ошибки и документы без опасных ошибок. Итоговые тексты независимо оценивают два предметных эксперта, не знающие условий испытания; разногласия разбирает третий. Ошибки, спорные профессиональные решения и непроверяемые утверждения размечаются отдельно.

Основной результат: доля всех назначенных задач, завершившихся выпуском текста хотя бы с одной серьёзной опасной ошибкой.

Сопутствующие показатели, не позволяющие «обыграть» основной: доля задач, выполненных приемлемо и в срок; доля заранее известных опасных ошибок, оставшихся к выпуску; новые опасные ошибки, внесённые при исправлении; доля обоснованных предупреждений и доля найденных опасных ошибок; время и нагрузка человека (например, по шкале NASA-TLX [6]); масштаб воздействия — число затронутых решений или людей. Без знаменателя число ошибок ничего не говорит о риске: если выпуск документов вырос многократно, меньшая доля ошибок ещё не означает меньшего вреда.

Тяжесть оценивается по общей рамке, которую каждая область наполняет своими примерами: S0 — вредного последствия не ожидается; S1 — небольшое, быстро устранимое; S2 — существенное, преимущественно обратимое; S3 — тяжёлое или длительное последствие для здоровья, прав или жизненных условий; S4 — катастрофическое, включая смерть или необратимый тяжёлый вред. Это порядковые категории, а не веса: S4 не равно четырём S1, и снижение мелких ошибок не компенсирует появления тяжёлых. Отдельно оцениваются вероятность, число затронутых людей и обратимость. Вопрос для оценки: что правдоподобно произойдёт, если по этому тексту поступят предусмотренным образом?

Условия испытаний включают дефицит времени и материал за гранью компетенции оператора — там, где опасность наибольшая. Для медицинских применений полезно руководство DECIDE-AI [7].

Масштаб. Пилот — одна область и один тип документов: например, 24 оператора по 8 разных заданий в двух условиях, всего 192 сессии, со случайным порядком условий. Пилот проверяет задания, время, понятность предупреждений и согласие экспертов, но не подтверждает безопасность от редких тяжёлых ошибок. Для подтверждения нужно больше: например, чтобы уловить снижение доли ошибочных выпусков с 20% до 10%, требуется порядка 200 независимых наблюдений на условие. Ноль событий не означает нулевого риска: при 100 наблюдениях без события верхняя 95%-ная граница вероятности — около 3%.

Не является доказательством: число предупреждений; удовлетворённость пользователей проверкой; общие приписки вида «ИИ может ошибаться»; один убедительный ответ инструмента на вопрос «где здесь опасное место?» — с этого вопроса проверка только начинается.

9. Рабочие ответы на открытые вопросы

Как сравнивать тяжесть между областями? Согласовать общий смысл категорий S0–S4, но пользоваться отдельными предметными шкалами. Не складывать медицинский, правовой и информационный вред в единый балл.

Что значит «заметно меньше»? Заранее задать практически значимое снижение, допустимый остаточный риск и ограничения по сопутствующим показателям. Публиковать оценку эффекта с интервалом неопределённости.

Может ли обычная модель в хорошем процессе соответствовать П2? По утверждению А — да, если это подтверждено. Утверждение Б о специальном обучении оценивается отдельно, и для полного П2 нужно оба.

Как оценивать второй круг при автономной работе? В отдельном профиле испытаний действий: соблюдение границ разрешённого, безопасная остановка, вмешательство человека, последствия сбоев. Успех на текстах сюда автоматически не переносится.

А что бы добавили, убрали или оспорили вы, читатель?

10. Соседи и новизна

Спецификация не объявляет новыми ни задачу безопасного взаимодействия человека и системы, ни помощь до подписи. Ближайшие соседи:

Шкала готовности к использованию человеком ANSI/HFES 400-2021 (Human Readiness Levels) — девять уровней готовности технологии к безопасному и эффективному использованию человеком [8]. Это готовность системы к применению, а не поколения ИИ по снижению вредных ошибок.

Модель зрелости калибровки доверия (TCMM, Steinmetz и соавторы, 2025) — уровни зрелости оценки ИИ, высший включает работу команды «человек +

ИИ» [9]. Уровни описывают полноту знания о системе, а не доказанную величину снижения вреда.

Человекоцентричный ИИ (Shneiderman, 2020) — надёжность, безопасность, человеческий контроль и автоматизация рассматриваются вместе [10]; границы поколений не предлагается. Рамка управления рисками NIST AI RMF оценивает безопасность в контексте применения, но это не классификация поколений [11].

Предшественники отдельных функций: CriticGPT — модель, обученная помогать находить ошибки [12]; игры «доказывающий — проверяющий» — обучение ради проверяемости [13]; функция Verify в юридическом помощнике Thomson Reuters — по описанию самой компании [14]. Их существование не означает, что критерий П2 уже достигнут.

Принцип «полезный, честный, безвредный» [15] уже охватывает честность, неопределённость и вредные советы, а не только отказ от опасного содержания. Спецификация не противопоставляет себя ему, а выделяет конкретный объект испытания — совместную работу — и конкретное основание классификации.

Предлагаемое новое: использовать подтверждённое снижение опасных ошибок в совместной работе как критерий поколения ИИ, рассматривая безопасность в трёх кругах. Точного предшественника этой совокупности поиск не нашёл; это результат поиска, а не доказательство первенства.

Авиационный образ — авторская аналогия. Деление истребителей на поколения само неофициально и спорно, а возвращение пилота иллюстрирует прежде всего первый круг. Пример защитной функции — система Auto-GCAS, которой приписывают спасение одиннадцати пилотов F-16 [16].

Литература

[1] Капустин И. Второе поколение ИИ. Эссе, «Книга-куст», версия 1.0. 2026. DOI 10.5281/zenodo.23257293. Открыть источник

[2] Капустин И. Язык змеи. Глава 1 «Книги-куста», версия 1.0. 2026. DOI 10.5281/zenodo.23164404. Открыть источник

[3] Капустин И. Слепые котята и воспитатели их новых моделей ИИ. Эссе. 2026. DOI 10.5281/zenodo.22924768. Открыть источник

[4] Recchia G. et al. Confirmation Bias: A Challenge for Scalable Oversight. Proceedings of the AAAI Conference on Artificial Intelligence. 2026 (препринт arXiv:2507.19486, 2025). Открыть источник

[5] Sensor Fusion: The Secret Sauce that Makes the F-35 Revolutionary. The National Interest (иллюстрация аналогии). Открыть источник

[6] NASA. Task Load Index (NASA-TLX). Описание инструмента оценки субъективной нагрузки. Открыть источник

[7] Vasey B. et al. Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI. 2022. Открыть источник

[8] ANSI/HFES 400-2021. Human Readiness Level Scale in the System Development Process. Human Factors and Ergonomics Society (описание стандарта). Открыть источник

[9] Steinmetz S. T. et al. The Trust Calibration Maturity Model for Characterizing and Communicating Trustworthiness of AI Systems. 2025. Препринт arXiv:2503.15511. Открыть источник

[10] Shneiderman B. Human-Centered Artificial Intelligence: Reliable, Safe & Trustworthy. 2020. Препринт arXiv:2002.04087. Открыть источник

[11] NIST. AI Risk Management Framework (AI RMF 1.0): Characteristics of Trustworthy AI Systems. 2023. Открыть источник

[12] McAleese N. et al. LLM Critics Help Catch LLM Bugs. 2024. Препринт arXiv:2407.00215. Открыть источник

[13] Kirchner J. H. et al. Prover-Verifier Games improve legibility of LLM outputs. 2024. Препринт arXiv:2407.13692. Открыть источник

[14] Colbert E. If You Can't Verify It, You Can't Sign It. Thomson Reuters Institute, 05.05.2026 (материал компании о собственном продукте). Открыть источник

[15] Askell A. et al. A General Language Assistant as a Laboratory for Alignment. 2021. Препринт arXiv:2112.00861. Открыть источник

[16] NASA. Resilient Autonomy Ends, Autonomy Research Ongoing. 2021 (обновлено 2023). Открыть источник

Версия 0.2 от 9 октября 2026 года. Сопровождает эссе «Второе поколение ИИ». Текст написан с участием ИИ: Claude и ChatGPT (ChatGPT — также как рецензент версии 0.1).